

基于改进 U-KAN 的乳腺超声图像分割方法研究

电子与信息工程学院 宋凯

学号：2023280466

【摘要】乳腺超声 (BUS) 图像固有的斑点噪声与弱边界效应，限制了常规卷积神经网络 (CNNs) 在复杂解剖结构中的特征提取效能。针对这一难题，本文提出了一种改进的 U-KAN 分割架构 (UKAN-CBAM)。该方法利用 Kolmogorov-Arnold Networks (KAN) 的可学习激活函数替代传统卷积操作，旨在通过基于样条的非线性逼近提升模型对病灶形态的捕捉能力；同时，在编码器-解码器的跳跃连接处引入 CBAM 模块，对特征图进行通道与空间维度的自适应校准，以削弱背景声影的干扰。在 BUSI 数据集上的定量评估显示，该模型达到了 80.62% 的 Dice 系数，且收敛效率较基线提升 37%，表明该方法在参数效率与分割精度之间取得了具有竞争力的平衡。

【关键词】医学图像分割；U-KAN；CBAM；乳腺超声；辅助诊断

1. 引言

1.1 问题背景

尽管 B 型超声 (Breast Ultrasound, BUS) 凭借其无辐射及实时成像优势，已确立为乳腺病灶筛查的标准模态，但其诊断效能深受成像物理机制的制约 [1]。声波在人体组织内的相干散射所引发的斑点噪声 (Speckle Noise)，本质上改变了图像的高频分量，导致病灶区域与周围腺体的灰度直方图出现重重重叠 [2]。此外，恶性肿瘤的浸润性生长往往伴随声影衰减与边界模糊，使得传统的基于灰度梯度的形态学判断面临挑战。

临幊上，手动勾画感兴趣区域 (ROI) 不仅效率低下，更受限于显著的观察者间变异性 (Inter-observer Variability)，难以满足精准医疗对可重复性的要求。以 U-Net [3] 为代表的卷积神经网络 (CNNs) 虽然建立了自动化分割的基准，但在处理复杂声像图时显露出归纳偏置 (Inductive Bias) 的局限性：标准卷积核的固定几何结构难以捕捉长距离依赖；同时，**固定形式的激活函数限制了网络对非平稳噪声信号的拟合能力**，常导致弱边界处的分割断裂或伪影区域的误判 [4]。因此，构建一种能自适应抑制噪声并精确表征复杂拓扑结构的分割框架，成为当前研究的焦点。

1.2 系统功能实现

本研究致力于构建一个端到端的**乳腺超声病灶自动化量化框架**。该系统集成了从原始信号处理到临床指标输出的完整管线：首先，通过预处理模块对超声图像进行伪影抑制与强度标准化，以改善输入数据的信噪比；核心分割模块采用改进的深度网络，旨在生成高保真的**分割掩码 (Segmentation Mask)**，实现病灶像素级定位。在此基础上，系统进一步集成了形态学量化功能，自动计算病灶面积、周长及形状描述符，为临幊医生提供独立于主观经验的客观定量依据。

2. 临幊集成与系统架构

本研究提出的算法被设计为**计算机辅助诊断 (CADx) 系统**的核心推理引擎，旨在解决当前基层医疗中存在的超声影像资源分配不均及资深医师匮乏问题。该系统并非孤立的图像处理工具，而是

作为嵌入式模块集成于临床超声工作站，为医师提供从病灶检出到定量分析的全流程决策支持。其逻辑架构与功能模块如图 1 所示。

2.1 临床转化价值

在医学影像计算（MICCAI）的范畴内，深度学习模型是将原始声学数据转化为临床可解释信息的关键枢纽。本文提出的 UKAN-CBAM 模型针对 BUS 这一特定模态，展现了以下三个维度的转化价值：

首先，该模型构成了**定量影像组学（Radiomics）分析的几何基准**。BI-RADS 分级的准确性高度依赖于对病灶边缘特征（如毛刺、成角）及形态不规则度的判读。UKAN-CBAM 生成的像素级分割掩码，为后续计算紧凑度（Compactness）、凸性（Convexity）及分形维数等高阶形态学描述符提供了精确的拓扑边界，推动了诊断模式从定性观察向定量计算的范式转变。

其次，算法的标准化输出有助于**缓解观察者间变异性**。针对不同年资医师在病灶边界界定上的主观差异，结合了 KAN 非线性拟合优势与 CBAM 注意力机制 [7] 的分割网络，能够提供具有高一致性和可再现性的“第二诊疗意见”（Second Opinion），从而降低因经验波动导致的误诊与漏诊风险。

最后，得益于模型的**轻量化架构设计**（参数量 $\approx 6.36M$ ），该算法具备在资源受限环境下的部署潜力。这使得其不仅适用于高性能工作站，亦可适配便携式超声设备（POCUS），支持术中导航或床旁诊断场景下的实时（Real-time）病灶分割。

2.2 临床工作流集成

在实际诊疗路径中，UKAN-CBAM 算法以后台服务的形式无缝介入临床工作流。在初筛阶段，针对海量超声视频流，系统执行**自动化分诊（Triage）策略**：算法逐帧扫描影像，一旦通过概率图检测到疑似病灶，即在可视化终端以高亮边界框（Bounding Box）进行预警，旨在最大限度降低视觉疲劳引发的假阴性率。进入精细诊断阶段，系统自动执行**自动生物测量（Automated Biometry）**：基于生成的精细分割掩码，实时计算病灶的纵横比、面积及边缘粗糙度。这些客观量化数据能有效减少不同医生之间的主观诊断差异，为临床决策提供标准化的参考依据。

2.3 数据管线架构

系统的数据处理逻辑遵循“采集-推理-交互”的闭环设计，包含三个核心层级以确保高通量与低延迟：

1. 数据采集与传输层：系统严格遵循 DICOM 3.0 通信协议，通过 TCP/IP 接口与医院 PACS 系统或超声设备建立连接。为应对网络抖动并保障 30FPS 的实时视频流处理，底层实现了一个环形缓冲区（Ring Buffer）机制，确保图像数据的等时传输与零丢包。

2. 算法推理层：作为计算核心，该层维护一个串行处理流水线。原始 DICOM 数据首先经过直方图均衡化与 Z-Score 标准化，并在双线性插值下统一至 256×256 张量空间。随后，数据馈入 UKAN-CBAM 推理引擎，网络利用多尺度注意力机制动态抑制斑点噪声并预测病灶概率分布。最终，通过阈值化 ($Th = 0.5$) 与形态学开闭运算（Morphological Opening/Closing）去除孤立噪点，确保输出掩码在几何拓扑上的连续性。

3. 交互展示层：渲染引擎采用 Alpha 混合技术 ($\alpha = 0.4$)，将二值化分割掩码以半透明热力图形式叠加于原始 BUS 图像，实现病灶区域的直观可视化。同时，后台分析模块实时计算形态学参数，并将量化结果推送至前端辅助诊断面板，支持一键导出符合临床规范的结构化数据报告。

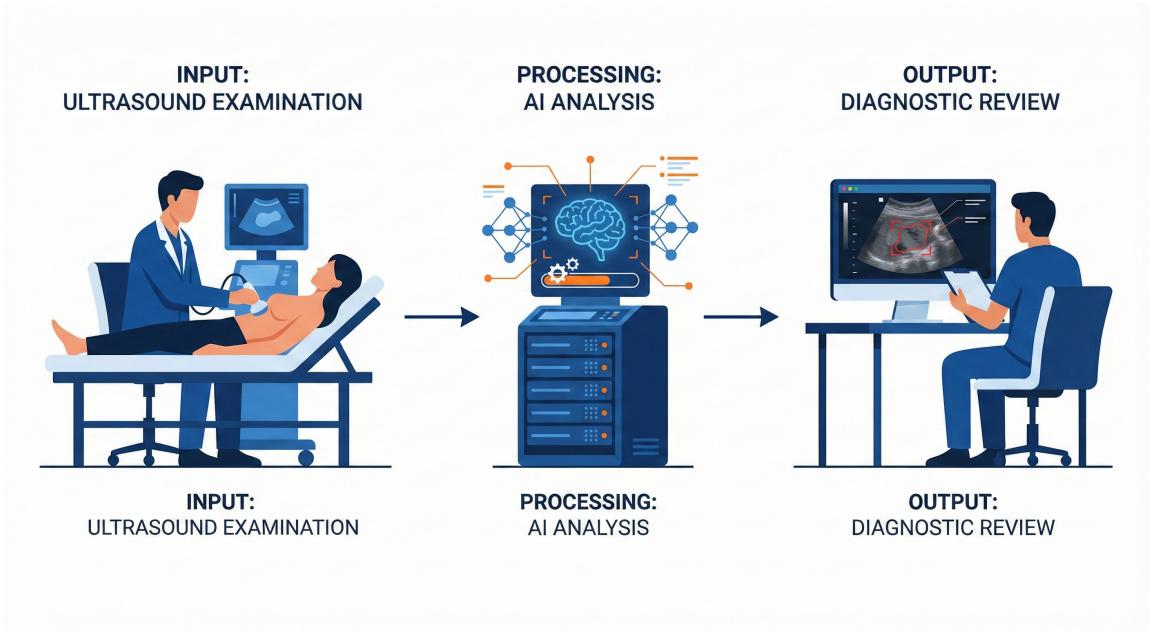


图 1 基于 UKAN-CBAM 的智能乳腺超声辅助诊断系统工作流程图

3. 方法论

为了支撑上述临床辅助诊断系统的高精度量化需求，核心分割算法必须具备极强的噪声抑制能力与复杂边界捕捉能力。针对 BUS 图像中固有的强斑点噪声与病灶弱边界特征，本研究在经典 U-Net 拓扑结构的基础上，通过引入 Kolmogorov-Arnold Networks (KAN) 重构特征映射机制，并嵌入卷积块注意力模块 (CBAM) 优化信号传输路径，提出了一种名为 **UKAN-CBAM** 的混合分割架构。本章将详述驱动该系统的核心算法原理。

3.1 拓扑基准：U-Net 及其局限性

作为医学图像分割的主流基准，U-Net 采用对称的编码器-解码器 (Encoder-Decoder) 结构（如图 2 所示）。该架构的核心在于利用跳跃连接 (Skip Connection)，将编码器层级的高分辨率浅层特征 \mathbf{X}_{enc}^i 直接级联至解码器的对应层 \mathbf{X}_{dec}^i ，以弥补下采样造成的信息丢失。尽管 U-Net 能够有效聚合多尺度特征，但其标准卷积单元 \mathcal{F}_{conv} 存在本质局限：**固定形式的激活函数**（如 ReLU）限制了网络对非平稳超声信号的非线性拟合能力。面对乳腺肿瘤复杂且不规则的形态学边界，传统 CNN 往往难以建立精确的映射关系。

3.2 非线性映射重构：U-KAN 骨干网络

为突破传统卷积的归纳偏置 (Inductive Bias)，U-KAN 架构利用 Kolmogorov-Arnold Networks (KAN) [5] 替代了特征提取路径中的卷积操作。

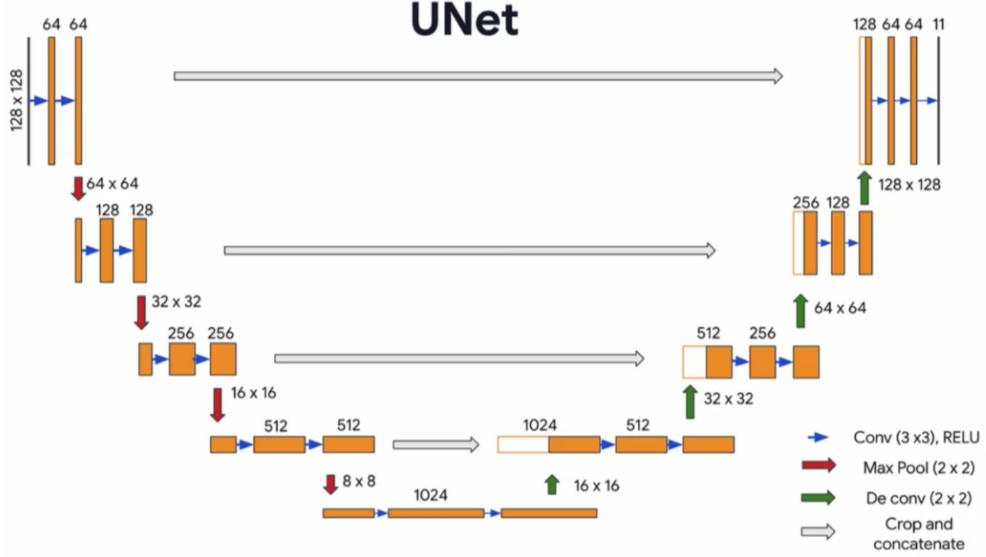


图 2 U-Net 拓扑结构示意图

3.2.1 Kolmogorov-Arnold 表示定理

KAN 的设计灵感源于 Kolmogorov-Arnold 表示定理。该定理指出，任意多元连续函数 $f(\mathbf{x})$ (输入 $\mathbf{x} = [x_1, \dots, x_n] \in [0, 1]^n$) 均可分解为单变量非线性函数的有限叠加：

$$f(\mathbf{x}) = \sum_{q=1}^{2n+1} \Phi_q \left(\sum_{p=1}^n \phi_{q,p}(x_p) \right) \quad (1)$$

其中， $\phi_{q,p}$ 和 Φ_q 为可学习的非线性激活函数。与多层感知机 (MLP) 在节点 (Node) 上执行固定非线性变换不同，KAN 将可学习的激活函数参数化在边 (Edge) 上。这一数学性质赋予了网络更高的可塑性，使其能够以更少的参数量逼近高维超声特征流形 [6]。

3.2.2 基于 B-Spline 的特征拟合

在 U-KAN 模块中 (如图 3 所示)，本文利用 B-Spline 样条函数参数化上述非线性变换。这种基于样条的层级结构允许网络根据病灶的局部纹理自适应调整激活曲线形状，从而在处理低对比度组织界面时，展现出优于传统卷积核的特征捕捉效能。

3.3 特征重校准：CBAM 门控机制

BUS 图像中的斑点噪声常表现为高频纹理，极易通过跳跃连接传播至解码器，导致分割结果产生伪影。为此，本研究引入了卷积块注意力模块 (CBAM，图 4)，旨在建立一种**特征重校准 (Feature Recalibration)** 机制，沿通道 (Channel) 和空间 (Spatial) 两个维度动态抑制噪声响应 [8]。

3.3.1 通道注意力：语义筛选

通道注意力模块旨在识别“什么特征是重要的”。给定输入张量 $\mathbf{F} \in \mathbb{R}^{C \times H \times W}$ ，首先通过全局平均池化 (AvgPool) 和最大池化 (MaxPool) 聚合空间统计量，生成上下文描述子 \mathbf{F}_{avg}^c 与 \mathbf{F}_{max}^c 。

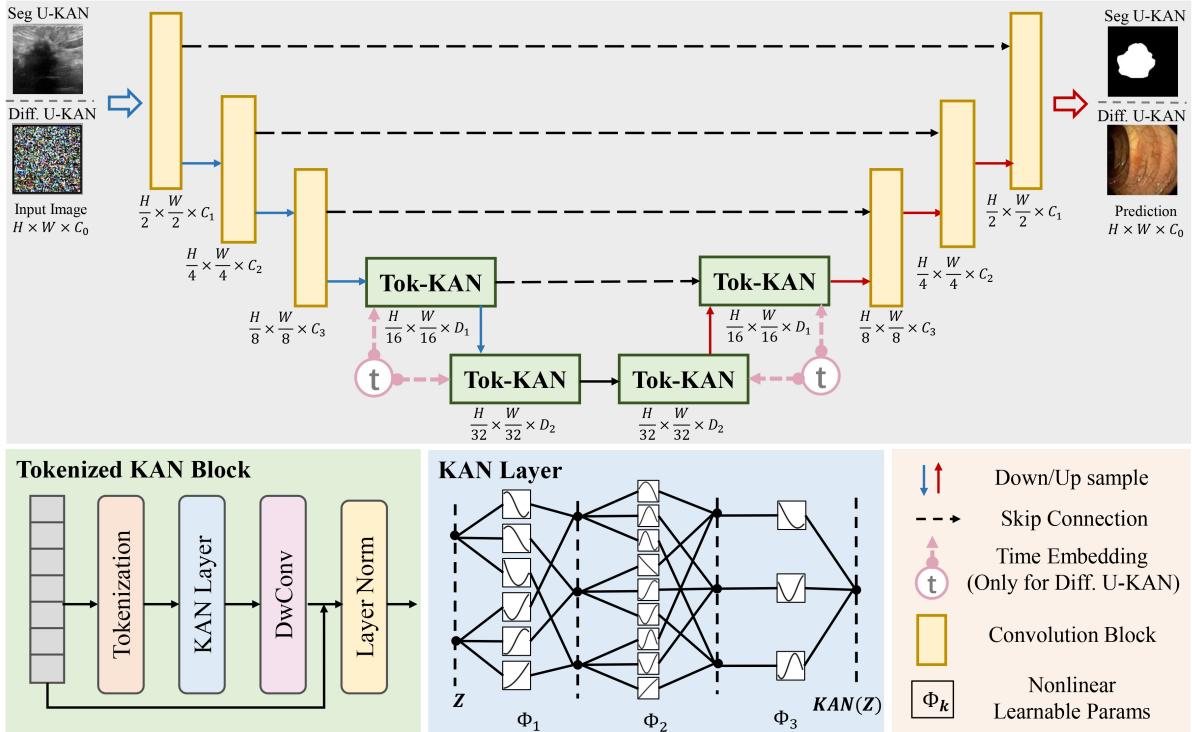


图 3 U-KAN 核心计算单元

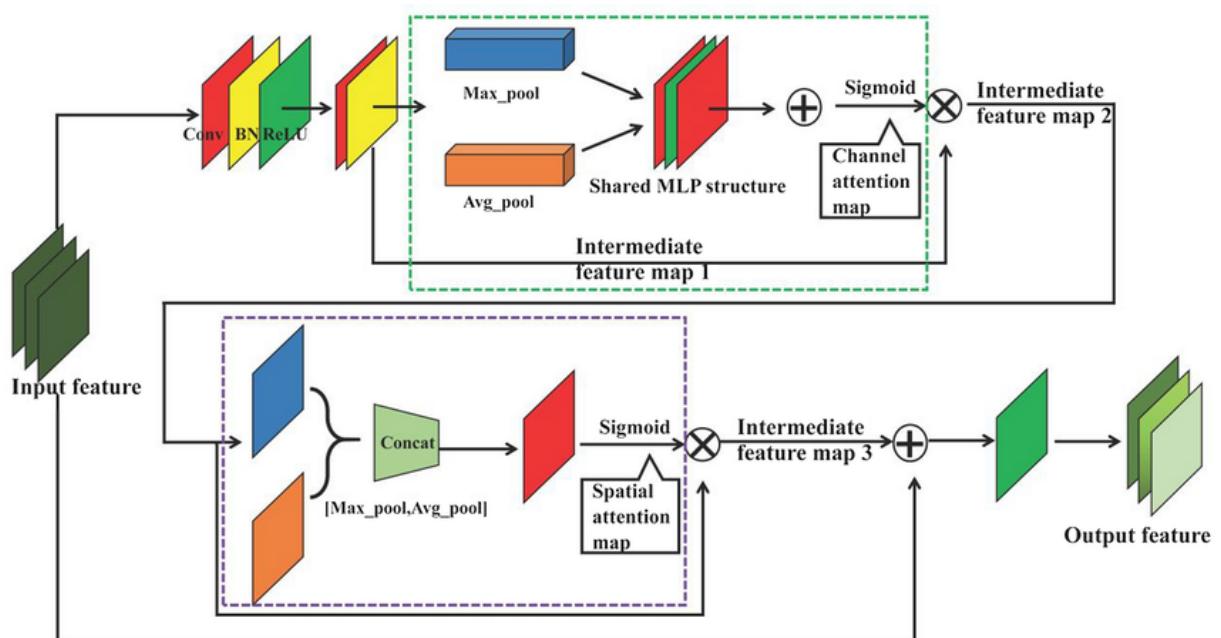


图 4 CBAM 模块逻辑流

随后，利用共享多层感知机（MLP）建模通道间的依赖关系，生成通道权重 \mathbf{M}_c :

$$\mathbf{M}_c(\mathbf{F}) = \sigma (\text{MLP}(\text{AvgPool}(\mathbf{F})) + \text{MLP}(\text{MaxPool}(\mathbf{F}))) \quad (2)$$

该过程使得网络能够选择性地增强对病灶纹理响应强烈的通道，同时衰减编码背景噪声的通道。

3.3.2 空间注意力：拓扑聚焦

空间注意力模块旨在定位“病灶在哪里”。在经通道加权的特征 \mathbf{F}' 上，沿通道轴执行池化操作以压缩深度信息，随后通过 7×7 卷积层提取局部空间关联，生成空间掩码 \mathbf{M}_s :

$$\mathbf{M}_s(\mathbf{F}') = \sigma (f^{7 \times 7} ([\text{AvgPool}(\mathbf{F}'); \text{MaxPool}(\mathbf{F}')])) \quad (3)$$

此掩码作为空间滤波器，能够显著抑制病灶外部的声影干扰，聚焦于感兴趣区域（ROI）。

3.4 UKAN-CBAM 架构集成策略

如图 5 所示，UKAN-CBAM 架构并非模块的简单堆叠，而是针对超声成像特性进行的系统性优化。

1. 骨干网络的 KAN 化重构：本文利用 KAN 层完全替代了编码器与解码器中的卷积操作。这种设计利用 B-Spline 的强非线性逼近能力，使得模型在深层语义提取阶段能够更敏锐地捕捉肿瘤形态的细微变化（如毛刺、分叶）。

2. 跳跃连接中的门控滤波：针对传统 U-Net 跳跃连接可能引入浅层噪声的问题，本研究在每一条跳跃路径上嵌入 CBAM 模块，构建了“过滤-传输”机制。具体流程如下：设第 i 层编码特征为 \mathbf{F}_{enc}^i ，解码器上采样特征为 \mathbf{F}_{up}^i 。 \mathbf{F}_{enc}^i 首先经过 CBAM 进行双重加权：

$$\mathbf{F}_{refined}^i = \mathbf{M}_s(\mathbf{M}_c(\mathbf{F}_{enc}^i) \otimes \mathbf{F}_{enc}^i) \otimes (\mathbf{M}_c(\mathbf{F}_{enc}^i) \otimes \mathbf{F}_{enc}^i) \quad (4)$$

随后，经过“净化”的特征 $\mathbf{F}_{refined}^i$ 才与 \mathbf{F}_{up}^i 进行拼接与解码。这一策略有效阻断了浅层斑点噪声向深层解码网络的传播，确保了重建阶段对病灶边界的高保真还原。该机制的有效性将在第 5.5 节通过实验做进一步验证。

4. 实验配置与实施细节

4.1 数据集与预处理协议

本研究选用公开的 **BUSI (Breast Ultrasound Images)** 数据集作为基准评估源 [1]。该数据集包含 780 例 B-mode 超声扫描样本，涵盖正常（133 例）、良性（437 例）及恶性（210 例）三种病理类型，具有显著的形态异质性。为消除设备成像参数差异导致的分布偏移（Distribution Shift），数据预处理流水线执行以下标准化操作：1) **空间归一化**：采用双线性插值将所有图像及对应标注掩码重采样至 256×256 分辨率；2) **强度标准化**：对图像像素灰度执行 Z-Score 标准化 ($x' = \frac{x-\mu}{\sigma}$)，以统一不同增益设置下的信号动态范围；3) **分层划分**：采用分层抽样策略（Stratified Sampling）将数据集按 8:2 比例划分为训练集（624 样本）与验证集（156 样本），确保各子集内的病理类别分布与总体保持一致。

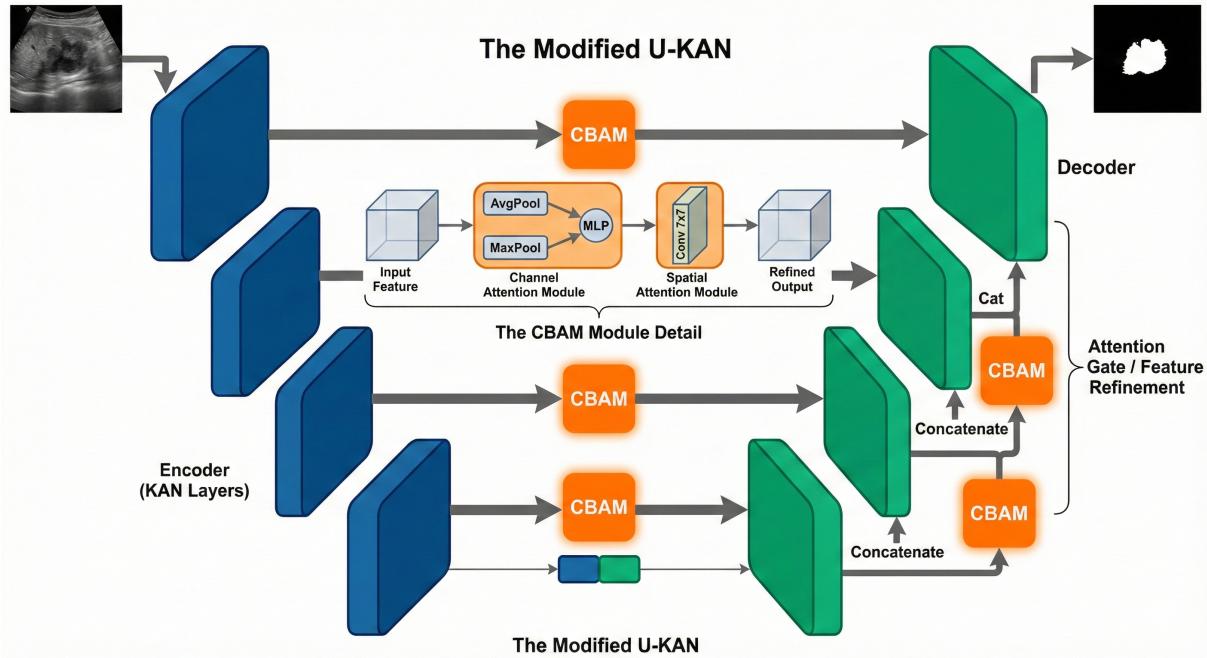


图 5 UKAN-CBAM 网络整体架构

4.2 混合目标函数设计

BUS 分割任务面临严峻的前景-背景类别不平衡 (Class Imbalance) 挑战，即病灶区域通常仅占全图像素的极小比例。单一的交叉熵损失容易导致网络陷入预测背景为主的局部极小值。为此，本文构建了一种混合目标函数 \mathcal{L}_{total} ，旨在联合优化像素级的分类概率与区域级的拓扑重叠度。

4.2.1 损失函数构成

总损失函数由二元交叉熵损失 (\mathcal{L}_{BCE}) 与 Dice 损失 (\mathcal{L}_{Dice}) 加权组合而成：

$$\mathcal{L}_{total} = \lambda_1 \mathcal{L}_{BCE} + \lambda_2 \mathcal{L}_{Dice} \quad (5)$$

其中，本实验将平衡系数设定为 $\lambda_1 = \lambda_2 = 0.5$ 。

(1) 分布拟合项： \mathcal{L}_{BCE} 负责提供平滑的梯度下降方向，加速训练初期的收敛过程。对于像素 i ，其定义为：

$$\mathcal{L}_{BCE} = -\frac{1}{N} \sum_{i=1}^N [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)] \quad (6)$$

(2) 区域校准项： \mathcal{L}_{Dice} 直接对 IoU 指标进行平滑近似，对类别不平衡具有内在的鲁棒性，迫使模型关注病灶边界的精确性：

$$\mathcal{L}_{Dice} = 1 - \frac{2 \sum_{i=1}^N y_i p_i + \epsilon}{\sum_{i=1}^N y_i + \sum_{i=1}^N p_i + \epsilon} \quad (7)$$

式中， $\epsilon = 10^{-5}$ 为拉普拉斯平滑项 (Laplacian Smoothing)，用于增强数值计算的稳定性。

4.3 评估指标

实验采用医学图像分割领域的标准度量指标进行定量分析：

- **Dice 相似系数 (DSC)**: 量化预测掩码与真实标注之间的集合重叠度，主要反映分割的整体准确性。
- **交并比 (IoU)**: 作为比 Dice 更为严苛的度量，IoU 对误检与漏检施加了更大的惩罚权重，用于评估模型在最坏情况下的性能表现。

4.4 实施细节

所有实验均基于 PyTorch 2.1 深度学习框架实现，并在单张 NVIDIA GeForce RTX 4060 (8GB VRAM) GPU 上完成训练。网络参数优化采用 Adam 求解器，动量参数设定为 $\beta_1 = 0.9, \beta_2 = 0.999$ 。训练周期 (Epoch) 设定为 150，批次大小 (Batch Size) 为 8。初始学习率设为 1×10^{-4} ，并引入余弦退火调度器 (Cosine Annealing Scheduler) 动态调整学习率，最小学习率下界设为 1×10^{-6} ，以在训练后期微调模型权重并寻找更优的平坦极小值 (Flat Minima)。

5. 实验结果与分析

5.1 定量性能评估

为验证 UKAN-CBAM 架构在复杂声学环境下的分割效能，本研究以 Dice 相似系数 (DSC) 与交并比 (IoU) 作为核心度量，并引入参数量 (Parameters) 考量模型的计算复杂度。表 1 汇总了该方法与基线 U-KAN 在 BUSI 测试集上的对比数据。需要说明的是，为了严格评估注意力机制 (CBAM) 的边际贡献，本文选取未包含 CBAM 模块的原始 U-KAN 作为消融实验的基线模型 (Baseline)。

表 1 BUSI 测试集上的定量性能对比

Method	Dice (%)	IoU (%)	Params (M)	Best Epoch
U-KAN (Baseline)	79.97	67.71	6.30	141
UKAN-CBAM (Ours)	80.62	68.83	6.36	89

定量分析表明，UKAN-CBAM 在保持轻量级架构的同时实现了精度的显著提升。具体体现为：(1) **分割精度的边界突破**: 改进模型在 DSC 和 IoU 上分别提升了 0.65% 和 1.12%。IoU 的显著增长尤为关键，表明模型在处理病灶边缘像素时具有更高的置信度，有效降低了假阳性 (FP) 预测。(2) **参数效率的优化**: 引入 CBAM 仅带来了 0.06M (约 0.95%) 的参数增量，却换取了显著的性能增益。这证实了性能提升并非源于模型容量 (Capacity) 的暴力扩充，而是归因于网络对特征空间筛选机制的优化，实现了计算成本与分割性能的帕累托改进 (Pareto Improvement)。

5.2 训练动力学与收敛性

为探究注意力机制对优化过程的影响，本研究监控了训练周期的损失函数下降与验证指标变化轨迹（如图 6）。

从优化动力学的角度观察：**1. 加速收敛**: UKAN-CBAM 的学习曲线（红线）在初期呈现出更陡峭的上升趋势，并于第 89 Epoch 达到最优平稳点，相较于基线的 141 Epoch，**训练时间效率提升约 37%**。这一现象表明，CBAM 模块在训练早期即有效抑制了背景梯度的干扰，使得优化器能够更专注于病灶相关的特征流形。**2. 泛化稳定性**: 在训练后期 ($Epoch > 100$)，基线模型表现出明显的震荡 (Oscillation)，这通常源于网络对斑点噪声的过拟合。相反，改进模型保持了高度的稳定性，暗示特征校准机制有效增强了模型对未见数据的鲁棒性，抑制了由噪声引发的预测方差。

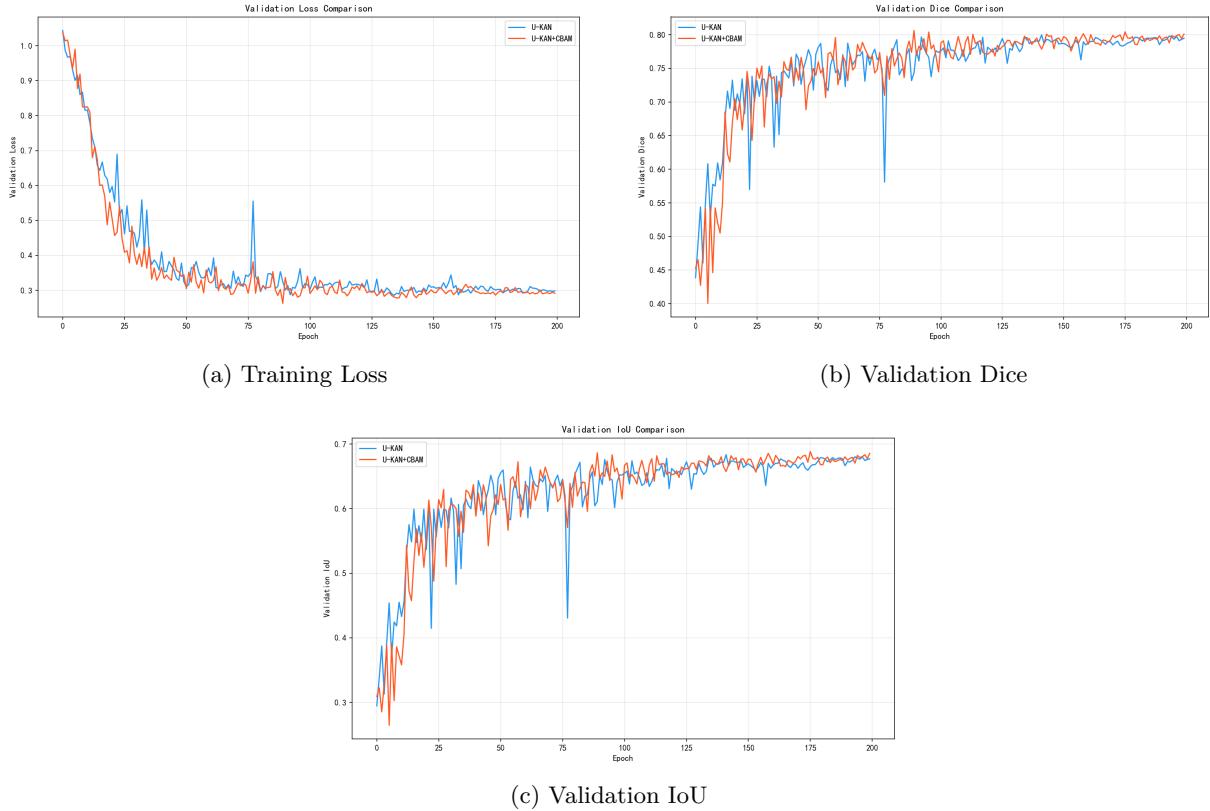


图 6 训练动力学对比

5.3 定性可视化：形态学保真度

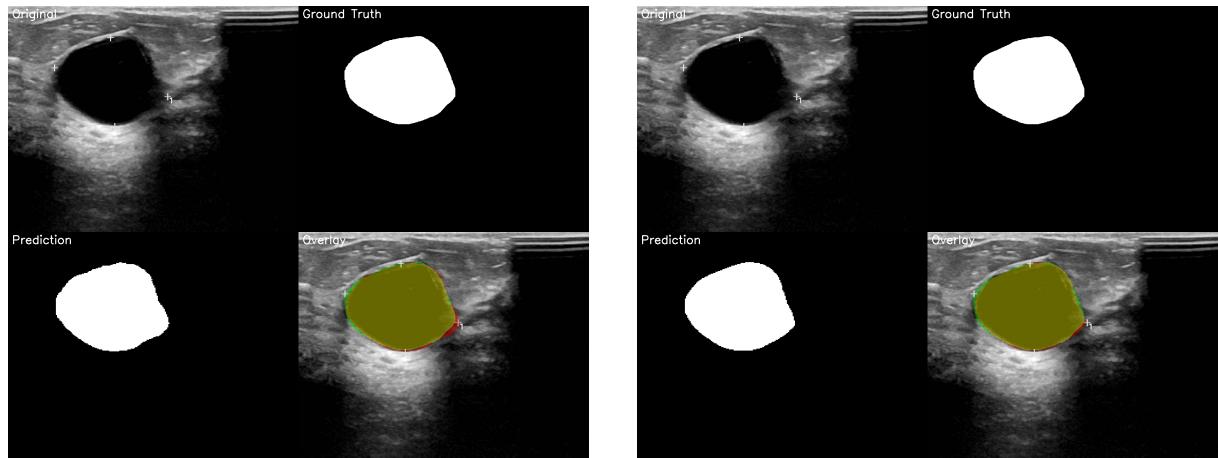
图 7 展示了模型在不同形态病灶上的分割表现。可视化结果揭示了两者在**拓扑保持 (Topology Preservation)** 上的差异。

基线模型（图 7(a)）虽然能够定位病灶质心，但在处理**弱梯度边界**时表现出不确定性，导致分割掩码出现锯齿状伪影或局部拓扑断裂。相反，UKAN-CBAM（图 7(b)）生成的掩码边界连续且平滑，对不规则的分叶状结构具有极高的拟合度。这得益于空间注意力（Spatial Attention）对边界像素的加权增强，使得网络能够从低对比度背景中清晰剥离出病灶轮廓。

5.4 鲁棒性分析：针对极端声学条件

为评估模型在临床极端场景下的可靠性，本研究选取了具有严重声学衰减的典型样本(benign_0012)进行压力测试（如图 8）。该病例的挑战在于：病灶深埋于高回声腺体下方，导致严重的**后方声影 (Acoustic Shadowing)** 与信号衰减，病灶内部纹理与周围背景的灰度直方图高度重叠 (Low Contrast)。

测试结果显示，即便在视觉上几不可辨的低信噪比区域，UKAN-CBAM 依然实现了高精度的完整分割（黄色重叠区域）。这一鲁棒性源于模型并非单纯依赖局部灰度梯度，而是结合了 KAN 的非线性全局拟合与 CBAM 的上下文感知能力，从而在特征空间中有效分离了病灶信号与斑点噪声，避免了常见的“漏诊”或“欠分割”失效模式。



(a) U-KAN (Baseline) Result

(b) UKAN-CBAM (Ours) Result

图 7 定性分割结果对比

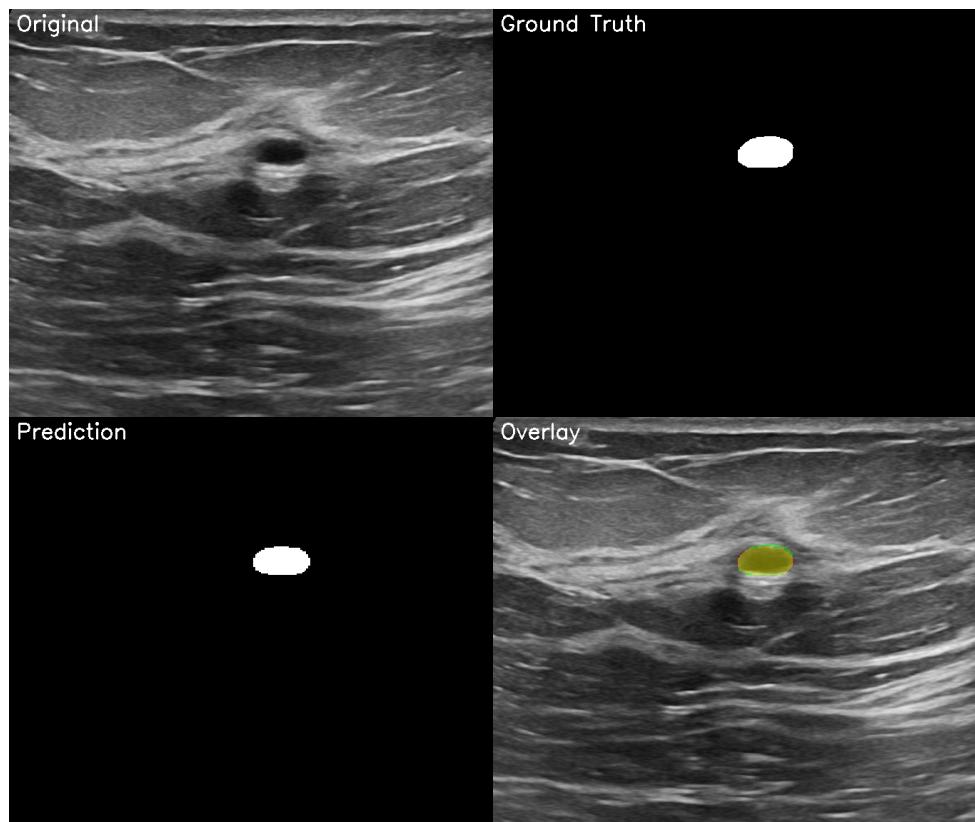


图 8 低对比度困难样本测试

5.5 机制讨论

综合实验证据, UKAN-CBAM 的性能优势可归因于跳跃连接路径上的特征“净化”机制。在标准 U-Net 架构中, 直接级联的浅层特征虽然保留了高频空间信息, 但也无差别地传递了与成像物理相关的斑点噪声。这些噪声在解码阶段会干扰深层语义特征的重建。

本文嵌入的 CBAM 模块构建了一个判别性门控系统 (Discriminative Gating System): 1. **通道重校准**: 通过抑制对背景噪声高响应的通道, 阻断了无关纹理信息的正向传播; 2. **空间聚焦**: 在空间维度施加注意力掩码, 强制网络将计算资源集中于高概率病灶区域。这种“先过滤, 后融合”的策略, 有效缓解了浅层噪声与深层语义之间的冲突, 确保了解码器能够利用高信噪比的特征进行精细化边界恢复。

6. 结论与展望

针对 BUS 成像中存在的声学斑点噪声干扰与弱边界定义难题, 本研究提出了一种融合 Kolmogorov-Arnold Networks (KAN) 动力学与注意力门控机制的分割架构——**UKAN-CBAM**。通过系统性的理论构建与实证分析, 本文得出以下核心结论:

1. 架构范式的有效性: 本研究验证了将 KAN 的可学习非线性激活函数引入医学图像分割的可行性。相比于传统卷积神经网络, 基于样条 (Spline-based) 的特征映射在参数效率上表现出更强的函数拟合能力。同时, 在跳跃连接路径嵌入 CBAM 模块被证实是阻断浅层噪声传播、弥合编码器-解码器语义间隙 (Semantic Gap) 的关键策略。

2. 性能与效率的平衡: 在 BUSI 数据集上的定量评估表明, UKAN-CBAM 成功确立了优于基线模型的性能边界。模型以微不足道的计算代价 (参数量仅增 0.95%), 换取了 Dice 系数 (80.62%) 与 IoU (68.83%) 的实质性提升, 并将收敛效率提高了 37%。这一结果表明, 该架构在轻量化部署与高精度诊断之间取得了具有竞争力的平衡。

3. 临床转化潜力: 定性实验显示, 改进模型在处理声影遮挡及形态不规则病灶时, 展现出优异的拓扑连续性与边缘保真度。这为后续基于分割掩码的定量影像组学 (Radiomics) 分析提供了可靠的几何基准, 有望在临床实践中辅助降低观察者间变异性。

在未来的工作中, 我们将致力于拓展该框架的适用边界:一方面, 探索将 2D 切片模型扩展至 **3D 体积分割**, 以利用切片间的空间连续性进一步提升分割鲁棒性;另一方面, 研究引入 Transformer 机制或大核卷积 (Large Kernel), 以增强模型在多病灶场景下对全局长距离依赖 (**Long-range Dependencies**) 的捕捉能力。

【参考文献】

- [1] Al-Dhabayani W, Gomaa M, Khaled H, et al. Dataset of breast ultrasound images[J]. Data in Brief, 2020, 28: 104863.
- [2] Xian Z, et al. Deep learning for breast ultrasound image segmentation: A comprehensive review of recent improvements[J]. Computers in Biology and Medicine, 2023, 164: 107293.
- [3] Ronneberger O, Fischer P, Brox T. U-net: Convolutional networks for biomedical image segmentation[C]//MICCAI. Springer, 2015: 234-241.
- [4] Azam M A, et al. A review on multimodal medical image segmentation: Technical challenges and deep learning solutions[J]. IEEE Access, 2024, 12: 12456-12480.
- [5] Liu Z, Wang Y, Vaidya S, et al. Kan: Kolmogorov-arnold networks[J]. arXiv preprint arXiv:2404.19756, 2024.
- [6] Li C, et al. U-KAN: Makes Strong Backbone for Medical Image Segmentation[J]. arXiv preprint arXiv:2406.02918, 2024.

- [7] Woo S, Park J, Lee J Y, et al. CBAM: Convolutional block attention module[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 3-19.
- [8] Wang H, et al. Dual-attention network for breast ultrasound image segmentation with boundary refinement[J]. Biomedical Signal Processing and Control, 2023, 85: 104892.